



Universidad Tecnológica de Bolívar

Mantenimiento Predictivo en Motores a Reacción Turbofan de la NASA mediante Redes Neuronales Recurrentes LSTM

Prevención de Fallos Catastróficos en Sistemas Aeroespaciales

Universidad Tecnológica de Bolívar

Curso de Modelos de Regresión y Series de Tiempo con IA

Grupo G, NCR 1705

Isaac David Sánchez Sánchez
Germán Eduardo de Armas Castaño
Katlyn Gutiérrez Cardona
Shalom Jhoanna Arrieta Marrugo

*Universidad Tecnológica de Bolívar
Cartagena de Indias, Colombia*

Noviembre 2025

Resumen

En entornos aeroespaciales e industriales, los motores a reacción constituyen activos críticos cuya falla repentina puede generar consecuencias catastróficas. Este trabajo presenta el desarrollo e implementación de un sistema de mantenimiento predictivo basado en redes neuronales recurrentes tipo *Long Short-Term Memory* (LSTM) para detectar patrones de degradación en motores turbofan de la NASA.

A diferencia de modelos tradicionales de series de tiempo (ARIMA, SARIMA, Holt-Winters), las arquitecturas LSTM capturan dependencias temporales no lineales y de largo alcance inherentes a procesos de degradación mecánica progresiva. En este trabajo, el modelo LSTM entrenado y evaluado alcanzó las siguientes métricas en el conjunto de prueba: **Accuracy = 98.31 %**, **Precision = 89.20 %**, **Recall = 97.00 %**, **F1 = 92.93 %**. La predicción se realiza con una ventana de alerta temprana de 20 ciclos antes del fallo, empleando lecturas de 21 sensores para 100 motores.

La metodología implementada incorpora técnicas rigurosas para prevenir fuga de datos temporales, incluyendo particionamiento por unidad física (motor completo), creación de secuencias temporales mediante ventanas deslizantes, y validación en motores nunca observados durante el entrenamiento. Los resultados demuestran la superioridad de arquitecturas de Deep Learning sobre modelos tradicionales para sistemas con degradación progresiva multivariate, contribuyendo a la optimización de costos operacionales y maximización de disponibilidad de activos críticos.

Palabras clave: Mantenimiento predictivo, LSTM, Deep Learning, Series temporales multivariadas, Detección de anomalías, Sistemas aeroespaciales, C-MAPSS NASA.

Índice

1. Introducción	5
1.1. Contexto y Motivación	5
1.2. Planteamiento del Problema	5
1.3. Pregunta de Investigación	6
1.4. Objetivos	6
1.4.1. Objetivo General	6
1.4.2. Objetivos Específicos	6
1.5. Contribuciones del Trabajo	6
1.6. Estructura del Documento	7
2. Marco Teórico	8
2.1. Modelos de Series Temporales: Panorama Histórico	8
2.1.1. Series Temporales Clásicas	8
2.1.2. Limitaciones para Mantenimiento Predictivo	8
2.2. Redes Neuronales Recurrentes	9
2.2.1. Fundamentos de RNN	9
2.2.2. Problema del Gradiente Desvaneciente	9
2.3. Long Short-Term Memory (LSTM)	10
2.3.1. Arquitectura y Componentes	10
2.3.2. Mitigación del Gradiente Desvaneciente	11
2.4. Bidirectional LSTM (BiLSTM)	11
2.4.1. Motivación	11
2.4.2. Ventajas para Detección de Degradación	12
2.5. Comparación Teórica: ARIMA vs. LSTM	12
2.6. Justificación Formal para el Uso de LSTM	12
2.6.1. Teorema de Aproximación Universal	12
2.6.2. Capacidad Expresiva	12
2.7. Ética y Gobernanza de Datos	13
2.7.1. Dataset C-MAPSS: Licencia y Uso	13
2.7.2. Sesgos Potenciales	13
2.7.3. Consideraciones de Seguridad	13
3. Dataset C-MAPSS y Análisis Exploratorio	14
3.1. Descripción del Dataset	14
3.1.1. Estructura del Dataset FD001	14
3.1.2. Variables del Sistema	14
3.2. Análisis Exploratorio de Datos	15
3.2.1. Distribución de Vida Útil	15
3.2.2. Análisis de Tendencias Temporales	15
3.3. Preprocesamiento de Datos	16
3.3.1. Eliminación de Variables Constantes	16
3.3.2. Creación de Etiquetas (Labeling Strategy)	16
3.3.3. Análisis de sensibilidad del umbral de etiquetado	16
3.3.4. Selección de Características Basada en Correlación	17

3.3.5. Distribución por secuencias y particiones	17
4. Metodología	19
4.1. Pipeline de Preprocesamiento para LSTM	19
4.1.1. Prevención de Fuga de Datos Temporal	19
4.1.2. Normalización de Características	19
4.1.3. ¿Por Qué NO Aplicar SMOTE en Series Temporales?	19
4.2. Construcción de Secuencias Temporales	20
4.2.1. Ventanas Deslizantes (Sliding Windows)	20
4.2.2. Separación Train/Validation sin Fuga	20
4.3. Arquitectura del Modelo LSTM	21
4.3.1. Diseño de la Red	21
4.3.2. Justificación de Componentes	21
4.3.3. Función de Pérdida y Optimización	22
4.3.4. Callbacks y Técnicas Anti-Overfitting	22
4.4. Protocolo de Entrenamiento	23
5. Resultados Experimentales	24
5.1. Configuración Experimental	24
5.1.1. Entorno Computacional	24
5.1.2. Hiperparámetros Finales	24
5.2. Evolución del Entrenamiento	24
5.3. Métricas de Desempeño en Conjunto de Test	25
5.4. Matriz de Confusión	25
5.5. Análisis de Errores	26
5.5.1. Distribución Temporal de Falsos Negativos	26
5.6. Curvas de evaluación y figuras complementarias	27
5.7. Comparación con Baseline	28
6. Discusión	30
6.1. Validación de Hipótesis Teóricas	30
6.1.1. Superioridad de LSTM sobre Modelos Lineales	30
6.2. Limitaciones del Estudio	30
6.2.1. Generalización a Otros Escenarios	30
6.2.2. Interpretabilidad del Modelo	30
6.3. Consideraciones de Deployment	31
6.3.1. Inferencia en Tiempo Real	31
6.3.2. Integración con Sistemas Existentes	31

1. Introducción

1.1. Contexto y Motivación

Los motores turbofan constituyen el sistema de propulsión fundamental en la aviación comercial y militar moderna, representando activos con valores unitarios superiores a millones de dólares y cuya integridad operacional es crítica para la seguridad de pasajeros, tripulación y/o carga. La industria aeroespacial enfrenta el desafío permanente de balancear dos objetivos aparentemente contradictorios: *(i)* maximizar la disponibilidad operacional de las aeronaves, y *(ii)* minimizar los riesgos asociados a fallos catastróficos en vuelo.

Los enfoques tradicionales de mantenimiento se han basado históricamente en dos paradigmas principales:

1. **Mantenimiento Reactivo:** Intervención post-fallo, caracterizado por costos elevados, tiempos de inactividad prolongados y riesgos de seguridad inaceptables.
2. **Mantenimiento Preventivo Programado:** Inspecciones periódicas basadas en horas de vuelo o ciclos operacionales, que si bien reduce riesgos, genera costos por reemplazo prematuro de componentes funcionales y ventanas de mantenimiento ineficientes.

La transición hacia paradigmas de **mantenimiento predictivo** representa un cambio de paradigma que permite anticipar fallos incipientes mediante el análisis continuo de datos operacionales, optimizando simultáneamente seguridad y eficiencia económica. Este enfoque, habilitado por avances en sensórica, telemetría en tiempo real y técnicas de Machine Learning, permite tomar decisiones basadas en el estado actual y proyección futura del activo, en lugar de intervalos temporales arbitrarios.

1.2. Planteamiento del Problema

A pesar de la disponibilidad de sistemas modernos de monitorización que capturan múltiples variables operacionales (temperatura, presión, vibraciones, RPM, entre otros), la interpretación de estos datos multivariados y temporalmente correlacionados permanece como un desafío técnico significativo. Los operadores aeronáuticos enfrentan limitaciones inherentes en su capacidad para:

- Identificar patrones sutiles de degradación en etapas tempranas
- Integrar información de múltiples sensores de forma coherente
- Distinguir entre variabilidad operacional normal y tendencias anómalas
- Proyectar la vida útil remanente con horizontes de anticipación útiles

El conjunto de datos **C-MAPSS** (Commercial Modular Aero-Propulsion System Simulation) desarrollado por el NASA Ames Research Center constituye un benchmark ampliamente reconocido en la comunidad científica para evaluar algoritmos de diagnóstico y pronóstico de salud (PHM - Prognostics and Health Management). Este dataset sintético, generado mediante simulaciones de alta fidelidad, reproduce condiciones realistas de operación y degradación de motores turbofan bajo múltiples escenarios operacionales.

1.3. Pregunta de Investigación

¿Es posible desarrollar un sistema de detección temprana de fallos en motores turbofan mediante arquitecturas de Deep Learning (LSTM) que supere las limitaciones de modelos tradicionales de series de tiempo, alcanzando métricas de desempeño compatibles con aplicaciones de seguridad crítica en aviación?

1.4. Objetivos

1.4.1. Objetivo General

Desarrollar e implementar un sistema de mantenimiento predictivo basado en redes neuronales recurrentes tipo LSTM, capaz de detectar patrones tempranos de degradación en motores turbofan de la NASA con al menos 20 ciclos de anticipación, alcanzando métricas de recall superiores al 85 % para garantizar la detección de fallos críticos.

1.4.2. Objetivos Específicos

1. Realizar un análisis exploratorio exhaustivo del dataset C-MAPSS FD001 para identificar variables predictivas y patrones de degradación característicos.
2. Diseñar e implementar un pipeline de preprocesamiento robusto que preserve la integridad temporal y evite fugas de información entre conjuntos de entrenamiento, validación y prueba.
3. Justificar teórica y empíricamente la selección de arquitecturas LSTM sobre modelos tradicionales de series de tiempo (ARIMA, SARIMA, Holt-Winters) y algoritmos de Machine Learning clásico.
4. Entrenar y optimizar un modelo LSTM bidireccional con técnicas de regularización para prevenir sobreajuste y garantizar generalización a motores no observados.
5. Evaluar el desempeño del sistema mediante métricas apropiadas para problemas de clasificación desbalanceada en contextos de seguridad crítica.
6. Documentar el proceso completo garantizando reproducibilidad, incluyendo código fuente, configuración de hiperparámetros y especificaciones del entorno computacional.

1.5. Contribuciones del Trabajo

Este trabajo realiza las siguientes contribuciones principales:

1. **Metodológicas:** Implementación rigurosa de técnicas de validación temporal que previenen fuga de datos por dependencias entre observaciones del mismo motor, incluyendo:
 - Particionamiento por unidad física completa (GroupShuffleSplit)
 - Separación de motores entre conjuntos train/validation/test sin superposición

- Construcción de secuencias temporales preservando continuidad física
- 2. **Teóricas:** Análisis comparativo fundamentado sobre la inadecuación de modelos univariados clásicos (ARIMA, SARIMA) para sistemas multivariados con degradación no lineal.
- 3. **Prácticas:** Sistema de mantenimiento predictivo alcanzando 98.31 % de exactitud, 89.20 % de precisión y 97.00 % de recall ($F1 = 92.93\%$), compatible con requisitos de seguridad aeronáutica.
- 4. **Reproducibilidad:** Código completo, documentación exhaustiva y análisis de decisiones metodológicas disponibles para validación y extensión por la comunidad científica.

1.6. Estructura del Documento

El resto de este documento se organiza de la siguiente manera:

- **Sección 2:** Marco teórico sobre modelos de series temporales y justificación de arquitecturas LSTM
- **Sección 3:** Descripción del dataset C-MAPSS FD001 y análisis exploratorio
- **Sección 4:** Metodología de preprocesamiento y construcción de features
- **Sección 5:** Arquitectura del modelo LSTM y proceso de entrenamiento
- **Sección 6:** Resultados experimentales y evaluación de desempeño
- **Sección 7:** Discusión, limitaciones y trabajo futuro
- **Sección 8:** Conclusiones y consideraciones éticas

2. Marco Teórico

2.1. Modelos de Series Temporales: Panorama Histórico

2.1.1. Series Temporales Clásicas

Los modelos tradicionales de series temporales han sido ampliamente utilizados en forecasting desde mediados del siglo XX. Los enfoques más prominentes incluyen:

ARIMA (AutoRegressive Integrated Moving Average) El modelo ARIMA(p, d, q) representa la clase más general de modelos lineales estacionarios, expresado como:

$$\phi(B)(1 - B)^d X_t = \theta(B)\epsilon_t \quad (1)$$

donde $\phi(B)$ es el polinomio autorregresivo de orden p , $\theta(B)$ el polinomio de medias móviles de orden q , $(1 - B)^d$ el operador de diferenciación de orden d , y $\epsilon_t \sim N(0, \sigma^2)$ ruido blanco.

SARIMA (Seasonal ARIMA) Extensión del modelo ARIMA que incorpora componentes estacionales:

$$\phi(B)\Phi(B^s)(1 - B)^d(1 - B^s)^D X_t = \theta(B)\Theta(B^s)\epsilon_t \quad (2)$$

donde s denota el período estacional y los operadores con mayúscula representan componentes estacionales.

Modelos de Suavizamiento Exponencial La familia de modelos de suavizamiento incluye:

- **Simple Exponential Smoothing (SES):**

$$\hat{y}_{t+1|t} = \alpha y_t + (1 - \alpha)\hat{y}_{t|t-1} \quad (3)$$

- **Holt-Winters:** Incorpora tendencia y estacionalidad mediante componentes aditivos o multiplicativos.

2.1.2. Limitaciones para Mantenimiento Predictivo

A pesar de su éxito en aplicaciones económicas y meteorológicas, estos modelos presentan restricciones fundamentales para el problema en estudio:

1. **Asunción de Linealidad:**

Los procesos de degradación mecánica exhiben comportamiento inherentemente no lineal. La evolución del desgaste en componentes rotativos sigue dinámicas del tipo:

$$\frac{dD}{dt} = f(D, T, P, \omega, \dots) \quad (4)$$

donde D representa el nivel de degradación y T, P, ω son temperatura, presión y velocidad angular. La función $f(\cdot)$ es típicamente no lineal y dependiente del estado.

2. Univarianza vs. Naturaleza Multivariada:

ARIMA clásico opera sobre series univariadas. Aunque existen extensiones multivariadas (VAR - Vector Autoregression), estas escalan pobremente con la dimensionalidad y mantienen asunciones de linealidad:

$$\mathbf{X}_t = \sum_{i=1}^p \mathbf{A}_i \mathbf{X}_{t-i} + \boldsymbol{\epsilon}_t \quad (5)$$

Para el dataset C-MAPSS con 21 sensores, se requeriría estimar $p \times 21^2$ parámetros, conduciendo a problemas de sobreajuste y complejidad computacional.

3. Estacionariedad:

ARIMA requiere estacionariedad (media y varianza constantes). Los procesos de degradación son inherentemente no estacionarios - la distribución de variables cambia sistemáticamente a medida que el motor se aproxima al fallo.

4. Incapacidad para Capturar Dependencias de Largo Alcance:

Modelos $AR(p)$ capturan dependencias hasta p pasos. Para motores con vidas útiles de 100-300 ciclos, patrones de degradación temprana (ciclo 50) pueden ser predictivos del fallo final (ciclo 200), requiriendo $p \approx 150$, lo cual es inviable.

5. Sensibilidad a Valores Atípicos:

Datos de sensores en entornos industriales contienen ruido, picos transitorios y anomalías. ARIMA, basado en mínimos cuadrados, es altamente sensible a outliers.

2.2. Redes Neuronales Recurrentes

2.2.1. Fundamentos de RNN

Las Redes Neuronales Recurrentes (RNN) introducen conexiones cíclicas que permiten a la red mantener un “estado oculto” $\mathbf{h}_t$ que resume información de pasos temporales anteriores:

$$\mathbf{h}_t = \tanh(\mathbf{W}_{hh} \mathbf{h}_{t-1} + \mathbf{W}_{xh} \mathbf{x}_t + \mathbf{b}_h) \quad (6)$$

$$\mathbf{y}_t = \mathbf{W}_{hy} \mathbf{h}_t + \mathbf{b}_y \quad (7)$$

donde $\mathbf{x}_t$ es la entrada en tiempo t , $\mathbf{h}_t$ el estado oculto, y $\mathbf{y}_t$ la salida.

2.2.2. Problema del Gradiente Desvaneciente

Durante el entrenamiento mediante Backpropagation Through Time (BPTT), el gradiente se propaga hacia atrás multiplicativamente:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}} = \sum_{t=1}^T \frac{\partial \mathcal{L}_t}{\partial \mathbf{W}} = \sum_{t=1}^T \frac{\partial \mathcal{L}_t}{\partial \mathbf{y}_t} \prod_{k=1}^t \frac{\partial \mathbf{h}_k}{\partial \mathbf{h}_{k-1}} \quad (8)$$

El término $\prod_{k=1}^t \frac{\partial \mathbf{h}_k}{\partial \mathbf{h}_{k-1}}$ involucra multiplicaciones repetidas de la matriz de pesos $\mathbf{W}_{hh}$. Si los valores singulares de $\mathbf{W}_{hh}$ son:

- < 1 : gradientes **desvanecen** exponencialmente con t
- > 1 : gradientes **explotan**

Este fenómeno impide a RNN vanilla aprender dependencias de largo plazo, esenciales para detectar degradación progresiva en motores.

2.3. Long Short-Term Memory (LSTM)

2.3.1. Arquitectura y Componentes

Las redes LSTM, propuestas por Hochreiter y Schmidhuber (1997), resuelven el problema del gradiente desvaneciente mediante una arquitectura sofisticada basada en *compuertas* (gates) y un *estado de celda* $\mathbf{C}_t$ que fluye con modificaciones mínimas.




Figura 1: Diagrama esquemático de una celda LSTM

Las ecuaciones que gobiernan una celda LSTM son:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (\text{Forget Gate}) \quad (9)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (\text{Input Gate}) \quad (10)$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad (\text{Candidate}) \quad (11)$$

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t \quad (\text{Cell State}) \quad (12)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (\text{Output Gate}) \quad (13)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t) \quad (\text{Hidden State}) \quad (14)$$

donde $\sigma(\cdot)$ es la función sigmoide, $\odot$ denota multiplicación elemento a elemento, y $[\mathbf{h}_{t-1}, \mathbf{x}_t]$ representa concatenación de vectores.

Interpretación de Compuertas

1. **Forget Gate** (9): Decide qué información del estado de celda anterior $\mathbf{C}_{t-1}$ debe descartarse. $\mathbf{f}_t \in [0, 1]^n$ donde valores cercanos a 0 indican "olvido total" cercanos a 1 retención completa".

Aplicación al mantenimiento predictivo: Permite olvidar fluctuaciones transitorias (pico de temperatura durante arranque) mientras retiene tendencias de degradación progresiva.

2. **Input Gate** (10) y **Candidate** (11): Determinan qué nueva información se incorporará al estado de celda. $\mathbf{i}_t$ regula la intensidad mientras $\tilde{\mathbf{C}}_t$ propone valores candidatos.
3. **Cell State Update** (12): Combina selectivamente información antigua (modulada por $\mathbf{f}_t$) con nueva información (modulada por $\mathbf{i}_t$).
4. **Output Gate** (13): Filtra el estado de celda para producir el estado oculto $\mathbf{h}_t$ que se propaga hacia adelante.

2.3.2. Mitigación del Gradiente Desvaneciente

La clave del éxito de LSTM radica en el flujo del gradiente a través del estado de celda. Durante BPTT:

$$\frac{\partial \mathbf{C}_t}{\partial \mathbf{C}_{t-1}} = \mathbf{f}_t + \text{términos de segundo orden} \quad (15)$$

A diferencia de RNN vanilla donde $\frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-1}}$ involucra multiplicación por $\mathbf{W}_{hh}$, aquí el gradiente fluye principalmente a través de suma aditiva, evitando el desvanecimiento exponencial. La compuerta forget $\mathbf{f}_t$ puede aprender a mantener valores cercanos a 1 para preservar gradientes en dependencias largas.

2.4. Bidirectional LSTM (BiLSTM)

2.4.1. Motivación

En aplicaciones de mantenimiento predictivo offline (no en tiempo real), tenemos acceso a la secuencia completa de ciclos históricos. Una BiLSTM procesa la secuencia en ambas direcciones:

$$\vec{\mathbf{h}}_t = \text{LSTM}_{forward}(\mathbf{x}_t, \vec{\mathbf{h}}_{t-1}) \quad (16)$$

$$\overleftarrow{\mathbf{h}}_t = \text{LSTM}_{backward}(\mathbf{x}_t, \overleftarrow{\mathbf{h}}_{t+1}) \quad (17)$$

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \quad (18)$$

2.4.2. Ventajas para Detección de Degradación

Consideremos un motor que opera durante 200 ciclos. Para clasificar el estado en el ciclo 150:

- **LSTM forward:** Analiza ciclos $1 \rightarrow 150$, capturando evolución histórica
- **LSTM backward:** Analiza ciclos $200 \rightarrow 150$, incorporando conocimiento del fallo final
- **BiLSTM:** Combina ambas perspectivas temporales

Esta capacidad es particularmente valiosa dado que el dataset C-MAPSS incluye run-to-failure completos donde conocemos el desenlace final de cada motor.

2.5. Comparación Teórica: ARIMA vs. LSTM

Tabla 1: Comparación de propiedades teóricas entre modelos ARIMA y LSTM

Propiedad	ARIMA	LSTM
Asume Linealidad	Sí	No
Manejo de no estacionariedad	Diferenciación	Nativo
Variables simultáneas	Limitado (VAR)	Nativo (multivariado)
Dependencias largas	Limitado (p finito)	Arbitrariamente largo
Extracción automática de features	No	Sí (representaciones latentes)
Robustez a outliers	Baja	Media-Alta

2.6. Justificación Formal para el Uso de LSTM

2.6.1. Teorema de Aproximación Universal

Las redes neuronales recurrentes con suficiente capacidad pueden aproximar cualquier función medible $f : \mathcal{X}^T \rightarrow \mathcal{Y}$, donde $\mathcal{X}^T$ representa secuencias de longitud T [?].

Formalmente, para cualquier función continua f sobre secuencias y cualquier $\epsilon > 0$, existe una RNN (y por ende LSTM) tal que:

$$\sup_{\mathbf{x} \in \mathcal{X}^T} ||f(\mathbf{x}) - \text{RNN}(\mathbf{x})|| < \epsilon \quad (19)$$

Este teorema no se aplica directamente a modelos ARIMA debido a su restricción a funciones lineales.

2.6.2. Capacidad Expresiva

Para un sistema de degradación gobernado por una ecuación diferencial estocástica:

$$d\mathbf{X}_t = \mu(\mathbf{X}_t, t)dt + \sigma(\mathbf{X}_t, t)d\mathbf{W}_t \quad (20)$$

donde μ, σ son funciones no lineales y $\mathbf{W}_t$ es un proceso de Wiener, LSTM puede aprender aproximaciones discretizadas de μ y σ directamente de datos, mientras que ARIMA requeriría conocimiento a priori de la estructura funcional.

2.7. Ética y Gobernanza de Datos

2.7.1. Dataset C-MAPSS: Licencia y Uso

El dataset C-MAPSS es de dominio público, distribuido por NASA bajo licencia abierta para investigación científica. No contiene información sensible ni datos personales identificables, eliminando preocupaciones de privacidad.

2.7.2. Sesgos Potenciales

1. **Sesgo de Simulación:** Los datos son sintéticos, generados bajo condiciones controladas que pueden no capturar toda la variabilidad de operación real.
2. **Sesgo de Selección:** El dataset FD001 representa un único escenario operacional (altitud única, condiciones Mach fijas).

Mitigación: Transparencia en limitaciones, validación cruzada con otros subsets C-MAPSS (FD002-004) como trabajo futuro.

2.7.3. Consideraciones de Seguridad

Dado que el sistema está orientado a aplicaciones de seguridad crítica:

- **Recall > Precision:** Preferimos falsos positivos (inspecciones innecesarias) sobre falsos negativos (fallos no detectados).
- **Validación Rigurosa:** Evaluación en motores completamente no observados durante entrenamiento.
- **Interpretabilidad Parcial:** Análisis de importancia de sensores mediante técnicas de saliency maps.

3. Dataset C-MAPSS y Análisis Exploratorio

3.1. Descripción del Dataset

El Commercial Modular Aero-Propulsion System Simulation (C-MAPSS) constituye un benchmark estandarizado desarrollado por el NASA Ames Research Center para evaluar algoritmos de diagnóstico y pronóstico en sistemas aeroespaciales [?].

3.1.1. Estructura del Dataset FD001

El subset FD001 utilizado en este estudio presenta las siguientes características:

Tabla 2: Características del dataset C-MAPSS FD001

Característica	Descripción
Número de motores	100 (entrenamiento)
Ciclos totales	20,631 observaciones
Variables operacionales	3 configuraciones de vuelo
Sensores	21 mediciones por ciclo
Condiciones operacionales	Altitud única, Mach único
Degradación	Progresiva hasta fallo
Tipo de datos	Run-to-failure completo

3.1.2. Variables del Sistema

Cada observación temporal $\mathbf{x}_t$ contiene:

1. Identificación:

- **motor:** Identificador único del motor (1-100)
- **ciclo:** Número de ciclo operacional

2. Configuraciones Operacionales:

- **config1:** Altitud (flight altitude)
- **config2:** Número Mach
- **config3:** Throttle resolver angle

3. Mediciones de Sensores ($s_1, \dots, s_{21}$):

- **Temperaturas:** Total temperature at fan inlet (T2), LPT outlet (T50), etc.
- **Presiones:** Total pressure at fan inlet (P2), HPC outlet (P30), etc.
- **Velocidades:** Physical fan speed (Nf), Physical core speed (Nc)
- **Flujos:** Bypass Ratio, Bleed Enthalpy, etc.

3.2. Análisis Exploratorio de Datos

3.2.1. Distribución de Vida Útil

La vida útil de los motores (medida en ciclos hasta fallo) exhibe variabilidad significativa:

$$\text{Ciclos}_{\min} = 128, \quad \text{Ciclos}_{\max} = 362, \quad \mu = 206,3, \quad \sigma = 46,8 \quad (21)$$

Esta heterogeneidad refleja condiciones iniciales y tasas de degradación variables, representando un desafío para modelos que asumen homogeneidad.

3.2.2. Análisis de Tendencias Temporales

Para cada sensor s_i , analizamos su evolución temporal promediando sobre todos los motores y ajustando una tendencia polinomial:

$$\mathbb{E}[s_i(t)] = \alpha_0 + \alpha_1 t + \alpha_2 t^2 \quad (22)$$

Hallazgos:

■ **Sensores con tendencia ascendente ($\alpha_1 > 0$):**

- **sensor2:** Total temperature at LPC outlet
- **sensor3:** Total temperature at HPC outlet
- **sensor4:** Total temperature at LPT outlet
- **sensor8:** Physical fan speed
- **sensor9:** Physical core speed
- **sensor11:** Static pressure at HPC outlet
- **sensor13:** Corrected fan speed
- **sensor14:** Corrected core speed
- **sensor15:** Bypass Ratio
- **sensor17:** Bleed Enthalpy

Interpretación: A medida que el motor se degrada, aumentan temperaturas y velocidades de compensación.

■ **Sensores con tendencia descendente ($\alpha_1 < 0$):**

- **sensor7:** Total pressure at HPC outlet
- **sensor12:** Ratio of fuel flow to Ps30
- **sensor21:** HPT coolant bleed
- **sensor22:** LPT coolant bleed

Interpretación: Pérdida de eficiencia de compresión con degradación.

■ **Sensores constantes ($|\alpha_1| \approx 0$):**

- **sensor1, sensor5, sensor10, sensor16, sensor18, sensor19**

Interpretación: Sensores no informativos.

3.3. Preprocesamiento de Datos

3.3.1. Eliminación de Variables Constantes

Sensores con varianza nula ($\sigma^2 = 0$) no aportan información predictiva. Formalmente:

$$\mathcal{S}_{\text{drop}} = \{s_i : \text{máx}(s_i) - \text{mín}(s_i) = 0\} \quad (23)$$

Resultado: $|\mathcal{S}_{\text{drop}}| = 7$ sensores eliminados.

3.3.2. Creación de Etiquetas (Labeling Strategy)

Dado un motor m con vida útil L_m ciclos, definimos un umbral de alerta temprana $\tau = 20$ ciclos:

$$y_t^{(m)} = \begin{cases} 0 & \text{si } t \leq L_m - \tau \quad (\text{NORMAL}) \\ 1 & \text{si } t > L_m - \tau \quad (\text{FALLO INMINENTE}) \end{cases} \quad (24)$$

Justificación del umbral $\tau = 20$:

- Ventana suficiente para acción correctiva (programación de mantenimiento)
- Balance entre anticipación y calidad de señal de degradación
- Alineado con prácticas aeronáuticas (inspecciones pre-vuelo)

Distribución de clases resultante:

$$N_{\text{NORMAL}} = 18,631 \text{ observaciones (90,3 \%)} \quad (25)$$

$$N_{\text{FALLO}} = 2,000 \text{ observaciones (9,7 \%)} \quad (26)$$

Esta distribución desbalanceada es representativa de escenarios reales donde fallos son eventos raros.

3.3.3. Análisis de sensibilidad del umbral de etiquetado

La elección del umbral de alerta temprana τ (30 ciclos en este estudio) impacta directamente en el trade-off anticipación vs. precisión. Se realizó un experimento de sensibilidad variando $\tau \in \{10, 20, 30\}$ y se reportaron para cada caso las métricas Precision, Recall y F1 en el conjunto de test.

Tabla 3: Resultados del experimento de sensibilidad del umbral (τ)

Umbral τ (ciclos)	Precision	Recall	F1
10	0.8729	0.8541	0.8634
20	0.8824	0.9120	0.8963
30	0.8920	0.9700	0.9293

3.3.4. Selección de Características Basada en Correlación

Para reducir dimensionalidad y eliminar ruido, aplicamos feature selection basado en correlación con la variable objetivo:

$$\mathcal{F}_{\text{selected}} = \{s_i : |\rho(s_i, y)| \geq \theta\} \quad (27)$$

con umbral $\theta = 0,2$. Resultado: $|\mathcal{F}_{\text{selected}}| = 14$ sensores retenidos.




Figura 2: Sensores con correlación significativa ($|\rho| \geq 0,2$) respecto a estado de fallo

3.3.5. Distribución por secuencias y particiones

Tras la creación de secuencias (ventana $L = 30$) y la partición por motor, las cantidades de secuencias en cada partición fueron aproximadamente:

Tabla 4: Conteo de secuencias por partición y distribución por clase

Partición	Secuencias totales	Normal (0)	Fallo (1)
Train_final	14,241	(aprox.) 12,800	(aprox.) 1,441
Validation	3,490	(aprox.) 3,100	(aprox.) 390
Test	3,490	3,090	400

4. Metodología

4.1. Pipeline de Preprocesamiento para LSTM

4.1.1. Prevención de Fuga de Datos Temporal

En problemas de series temporales con múltiples unidades (motores), la partición de datos requiere consideraciones especiales. Un split aleatorio tradicional conduciría a fuga de información:

Problema de Split Aleatorio: Si el Motor #42 tiene ciclos $[1, 2, \dots, 200]$ y un split aleatorio asigna ciclos $[1 - 150]$ a TRAIN y $[151 - 200]$ a TEST, el modelo aprende del pasado inmediato del mismo motor que debe predecir $\rightarrow$ **Sobreestimación de desempeño.**

Solución Implementada: GroupShuffleSplit

Particionamos por **motor completo**, no por ciclos individuales:

Algorithm 1 Partición sin fuga de datos temporal

- 1: $\mathcal{M} = \{\text{motor}_1, \dots, \text{motor}_{100}\}$ $\triangleright$ Conjunto de motores
 - 2: $\mathcal{M}_{\text{train}}, \mathcal{M}_{\text{test}} \leftarrow \text{GroupShuffleSplit}(\mathcal{M}, \text{test_size} = 0,2)$
 - 3: $\mathcal{D}_{\text{train}} = \{(t, \mathbf{x}_t, y_t) : \text{motor}(t) \in \mathcal{M}_{\text{train}}\}$
 - 4: $\mathcal{D}_{\text{test}} = \{(t, \mathbf{x}_t, y_t) : \text{motor}(t) \in \mathcal{M}_{\text{test}}\}$
 - 5: **ensure** $\mathcal{M}_{\text{train}} \cap \mathcal{M}_{\text{test}} = \emptyset$
-

Resultado:

- 80 motores $\rightarrow$ TRAIN (16,504 ciclos)
- 20 motores $\rightarrow$ TEST (4,127 ciclos)

4.1.2. Normalización de Características

Para facilitar convergencia de redes neuronales, aplicamos estandarización Z-score:

$$\tilde{s}_i = \frac{s_i - \mu_{s_i}^{(\text{train})}}{\sigma_{s_i}^{(\text{train})}} \quad (28)$$

Importante: Parámetros μ, σ se calculan **únicamente** sobre conjunto TRAIN y se aplican a TEST, evitando data leakage.

4.1.3. ¿Por Qué NO Aplicar SMOTE en Series Temporales?

SMOTE (Synthetic Minority Over-sampling Technique) genera muestras sintéticas mediante interpolación:

$$\mathbf{x}_{\text{synthetic}} = \mathbf{x}_i + \lambda(\mathbf{x}_{\text{nn}} - \mathbf{x}_i), \quad \lambda \in [0, 1] \quad (29)$$

Problema para LSTM:

- SMOTE crea observaciones aisladas sin continuidad temporal
- Motor requiere secuencia consecutiva: $[\text{ciclo}_{t-9}, \dots, \text{ciclo}_t]$
- Un “ciclo sintético 2.” entre ciclo 2 y 3 carece de significado físico
- Rompe la estructura de dependencia temporal que LSTM necesita

Decisión: Aceptar desbalance natural, usar métricas apropiadas (Precision, Recall) y loss functions ponderadas si es necesario.

4.2. Construcción de Secuencias Temporales

4.2.1. Ventanas Deslizantes (Sliding Windows)

Para cada motor m , construimos secuencias de longitud fija $L = 30$ ciclos:

$$\mathbf{X}_t^{(m)} = [\mathbf{x}_{t-L+1}^{(m)}, \mathbf{x}_{t-L+2}^{(m)}, \dots, \mathbf{x}_t^{(m)}] \in \mathbb{R}^{L \times d} \quad (30)$$

donde $d = 14$ es el número de sensores seleccionados.

La etiqueta corresponde al estado en el último ciclo de la ventana:

$$y_t^{(m)} = \text{estado en ciclo } t \quad (31)$$

Algorithm 2 Creación de secuencias con tracking de motor

```

1: function CREARSECUENCIAS( $\mathcal{D}, L$ )
2:    $\mathcal{S} \leftarrow \emptyset$  ▷ Conjunto de secuencias
3:   for cada motor  $m \in \mathcal{M}$  do
4:      $T_m \leftarrow$  número de ciclos del motor  $m$ 
5:     for  $t = L$  to  $T_m$  do
6:        $\mathbf{X}_t \leftarrow [\mathbf{x}_{t-L+1}^{(m)}, \dots, \mathbf{x}_t^{(m)}]$ 
7:        $y_t \leftarrow$  etiqueta en ciclo  $t$ 
8:        $\mathcal{S} \leftarrow \mathcal{S} \cup \{(\mathbf{X}_t, y_t, m)\}$  ▷ Guardar ID motor
9:     end for
10:  end for
11:  return  $\mathcal{S}$ 
12: end function

```

Pérdida de observaciones: Los primeros $L - 1 = 29$ ciclos de cada motor no pueden formar secuencias completas, resultando en pérdida de aproximadamente $29 \times 100 = 2900$ observaciones.

4.2.2. Separación Train/Validation sin Fuga

Para validación durante entrenamiento, subdividimos el conjunto TRAIN (80 motores) en:

- 64 motores $\rightarrow$ TRAIN_FINAL (14,241 secuencias)

- 16 motores $\rightarrow$ VALIDATION (3,490 secuencias)

Verificación de integridad:

$$\mathcal{M}_{\text{train_final}} \cap \mathcal{M}_{\text{val}} = \emptyset \quad (32)$$

$$\mathcal{M}_{\text{train_final}} \cap \mathcal{M}_{\text{test}} = \emptyset \quad (33)$$

$$\mathcal{M}_{\text{val}} \cap \mathcal{M}_{\text{test}} = \emptyset \quad (34)$$

Esto garantiza que métricas de validación y test reflejen capacidad de generalización a motores completamente no observados.

4.3. Arquitectura del Modelo LSTM

4.3.1. Diseño de la Red

La arquitectura propuesta combina capas LSTM bidireccionales con regularización mediante Dropout:

Tabla 5: Arquitectura del modelo LSTM propuesto

Capa	Tipo	Parámetros	Salida
Input	-	-	(30, 14)
BiLSTM_1	Bidirectional LSTM	64 units, return_seq=True	(30, 128)
Dropout_1	Dropout	rate=0.3	(30, 128)
LSTM_2	LSTM	32 units	(32)
Dropout_2	Dropout	rate=0.3	(32)
Dense_1	Dense + ReLU	32 units, L2=0.01	(32)
Dropout_3	Dropout	rate=0.2	(32)
Output	Dense + Sigmoid	1 unit	(1)
Total parámetros: 62,145 (todos entrenables)			

4.3.2. Justificación de Componentes

Bidirectional LSTM en primera capa: Dado que procesamos secuencias completas offline (no streaming), BiLSTM puede aprovechar contexto futuro:

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \quad (35)$$

donde $\vec{\mathbf{h}}_t$ procesa $t - L + 1 \rightarrow t$ y $\overleftarrow{\mathbf{h}}_t$ procesa $t \rightarrow t - L + 1$.

Dropout: Regularización estocástica que durante entrenamiento desactiva aleatoriamente el $p\%$ de neuronas:

$$\mathbf{h}_t^{\text{dropout}} = \mathbf{h}_t \odot \mathbf{m}_t, \quad \mathbf{m}_t \sim \text{Bernoulli}(1 - p) \quad (36)$$

Reduce sobreajuste forzando a la red a aprender representaciones distribuidas robustas.

Regularización L2: Penalización en función de pérdida:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{BCE}} + \lambda \sum_{\ell} \|\mathbf{W}_{\ell}\|_2^2 \quad (37)$$

con $\lambda = 0,01$, limita magnitud de pesos previniendo overfitting.

4.3.3. Función de Pérdida y Optimización

Binary Cross-Entropy: Para clasificación binaria con salida $\hat{y} \in (0, 1)$:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (38)$$

Optimizador Adam: Adaptive Moment Estimation combina momentum y RMSprop:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla_{\theta} \mathcal{L} \quad (39)$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) (\nabla_{\theta} \mathcal{L})^2 \quad (40)$$

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon} \hat{\mathbf{m}}_t \quad (41)$$

con learning rate inicial $\alpha = 0,001$, $\beta_1 = 0,9$, $\beta_2 = 0,999$.

4.3.4. Callbacks y Técnicas Anti-Overfitting

Early Stopping: Detiene entrenamiento si métrica de validación no mejora durante p épocas:

$$\text{stop if } \mathcal{L}_{\text{val}}^{(t)} \geq \min_{k \leq t-p} \mathcal{L}_{\text{val}}^{(k)} \quad (42)$$

Configuración: patience=15, monitor='val_loss', restore_best_weights=True.

ReduceLROnPlateau: Reduce learning rate cuando validación se estanca:

$$\alpha_{t+1} = \begin{cases} \alpha_t / \text{factor} & \text{si plateau detectado} \\ \alpha_t & \text{caso contrario} \end{cases} \quad (43)$$

Configuración: factor=0.5, patience=5.

4.4. Protocolo de Entrenamiento

Algorithm 3 Proceso de entrenamiento con validación rigurosa

```

1:  $\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{val}}, \mathcal{D}_{\text{test}} \leftarrow \text{ParticionPorMotor}(\mathcal{D})$ 
2:  $\mathcal{S}_{\text{train}}, \mathcal{S}_{\text{val}}, \mathcal{S}_{\text{test}} \leftarrow \text{CrearSecuencias}(\mathcal{D}, L = 30)$ 
3:  $\theta \leftarrow \text{InicializacionAleatoria}()$ 
4:  $\text{epoch} \leftarrow 0, \text{best\_loss} \leftarrow \infty, \text{patience\_counter} \leftarrow 0$ 
5: while  $\text{epoch} < \text{max\_epochs}$  do
6:   for cada batch  $\mathcal{B} \subset \mathcal{S}_{\text{train}}$  do
7:      $\nabla_{\theta} \mathcal{L} \leftarrow \text{Backpropagation}(\mathcal{B}, \theta)$ 
8:      $\theta \leftarrow \text{Adam}(\theta, \nabla_{\theta} \mathcal{L})$ 
9:   end for
10:   $\mathcal{L}_{\text{val}} \leftarrow \text{Evaluate}(\mathcal{S}_{\text{val}}, \theta)$ 
11:  if  $\mathcal{L}_{\text{val}} < \text{best\_loss}$  then
12:     $\text{best\_loss} \leftarrow \mathcal{L}_{\text{val}}$ 
13:     $\theta_{\text{best}} \leftarrow \theta$ 
14:     $\text{patience\_counter} \leftarrow 0$ 
15:  else
16:     $\text{patience\_counter} \leftarrow \text{patience\_counter} + 1$ 
17:    if  $\text{patience\_counter} \geq 15$  then
18:      break ▷ Early stopping
19:    end if
20:  end if
21:   $\text{epoch} \leftarrow \text{epoch} + 1$ 
22: end while
23: return  $\theta_{\text{best}}$ 

```

5. Resultados Experimentales

5.1. Configuración Experimental

5.1.1. Entorno Computacional

- **Hardware:** Mac, Apple M4 (ARM architecture)
- **Software:** Python 3.11.14, TensorFlow 2.15.1, Keras 2.15.0
- **Bibliotecas:** NumPy 1.26.4, Pandas 2.1.4, Scikit-learn 1.4.2
- **Reproducibilidad:** Random seed fijado en 42 para todos los componentes estocásticos

5.1.2. Hiperparámetros Finales

Tabla 6: Hiperparámetros del modelo LSTM

Parámetro	Valor
Longitud de secuencia (L)	30 ciclos
BiLSTM units	64
LSTM units (capa 2)	32
Dense units	32
Dropout rates	0.3, 0.3, 0.2
L2 regularization	0.01
Learning rate inicial	0.001
Batch size	64
Max epochs	50
Early stopping patience	15
ReduceLR patience	5
ReduceLR factor	0.5

5.2. Evolución del Entrenamiento

El modelo convergió en **30 épocas**, con early stopping activándose al detectar que la pérdida de validación no mejoraba desde la época 15.

Tabla 7: Métricas en épocas clave del entrenamiento

Época	Loss Train	Loss Val	Acc Train	Acc Val	Recall Val
1	0.345	0.151	0.934	0.970	0.947
15	0.026	0.035	0.990	0.989	0.963
30	0.012	0.072	0.996	0.985	0.934

Early stopping restauró pesos de época 15 (mejor val_loss)

Observaciones:

- Pérdida de validación alcanza mínimo en época 15 (0.035)
- Train loss continúa disminuyendo después de época 15 → señal de inicio de overfitting
- Early stopping previene deterioro de generalización

5.3. Métricas de Desempeño en Conjunto de Test

Evaluación en 20 motores completamente no observados (3,490 secuencias):

Tabla 8: Métricas finales del modelo LSTM en conjunto de test

Métrica	Valor	Interpretación
Accuracy	0.9831 (98.31 %)	98.31 % predicciones correctas
Precision	0.8920 (89.20 %)	89.20 % alarmas son válidas
Recall	0.9700 (97.00 %)	97 % fallos detectados
F1-Score	0.9293 (92.93 %)	Balance precision-recall
Specificity	0.9848 (98.48 %)	98.48 % normales correctos

5.4. Matriz de Confusión




Figura 3: Matriz de Confusión del modelo LSTM.

Generado en: Notebook - EDA y Modelado LSTM.ipynb — Sección Resultados Experimentales” (matriz de confusión del LSTM sobre el conjunto de test).

Análisis detallado:

1. **Verdaderos Negativos (3,043):** Ciclos normales correctamente clasificados

$$TN = 3,043 \quad \text{de } 3,090 \text{ normales} \quad (98,48 \%) \quad (44)$$

2. **Falsos Positivos (47):** Alarmas falsas

$$FP = 47 \quad \Rightarrow \quad 47 \text{ inspecciones innecesarias} \quad (45)$$

Costo: Moderado (inspección preventiva)

3. **Falsos Negativos (12):** Fallos NO detectados

$$FN = 12 \quad \text{de } 400 \text{ fallos} \quad (3 \%) \quad (46)$$

Riesgo: BAJO (solo 3% de fallos no detectados)

4. **Verdaderos Positivos (388):** Fallos correctamente detectados

$$TP = 388 \quad (97 \% \text{ de fallos capturados}) \quad (47)$$

5.5. Análisis de Errores

5.5.1. Distribución Temporal de Falsos Negativos

Analizamos en qué ciclos relativos al fallo se producen los 12 FN:

Tabla 9: Distribución de falsos negativos por ventana temporal

Ciclos antes del fallo	FN observados	Porcentaje
20-16	12	100.0 %
15-11	0	0.0 %
10-6	0	0.0 %
5-1	0	0.0 %

Interpretación: La totalidad de los FN (100 %) ocurren en la ventana más temprana (20-16 ciclos antes del fallo), donde la degradación es menos pronunciada. Esto indica que el modelo LSTM tiene excelente desempeño en la detección cercana al fallo. A medida que el fallo se aproxima (ventanas 15-11, 10-6 y 5-1 ciclos), la detección es perfecta sin ningún falso negativo.

5.6. Curvas de evaluación y figuras complementarias

Para apoyar la interpretación de las métricas presentamos las figuras principales generadas durante el EDA y el entrenamiento. A continuación se indican las imágenes que deben colocarse en el proyecto Overleaf (nombres de fichero):




Figura 4: Curvas de pérdida durante el entrenamiento del modelo.




Figura 5: Curvas de evolución durante el entrenamiento del modelo.

5.7. Comparación con Baseline

Para contextualizar el desempeño del modelo LSTM, comparamos con un modelo LightGBM (gradient boosting tradicional) entrenado sobre datos tabulares sin estructura temporal:

Tabla 10: Comparación LSTM vs. LightGBM

Métrica	LSTM	LightGBM	Diferencia
Accuracy	98.31 %	96.78 %	+1.53 pp
Precision	89.20 %	80.25 %	+8.95 pp
Recall	97.00 %	88.50 %	+8.50 pp
F1-Score	92.93 %	84.17 %	+8.76 pp
Observaciones test	3,890 seq.	4,127 ciclos	Diferentes
Tipo de entrada	Secuencias 30×14	Vectores 1×14	-

Hallazgos clave:

- LSTM supera a LightGBM en **todas las métricas**, demostrando la ventaja de modelar dependencias temporales
- **Recall superior** (+8.50 pp): LSTM detecta 97 % de los fallos vs. 88.5 % de LightGBM, crítico para seguridad
- **Precision mejorada** (+8.95 pp): reduce falsas alarmas de 87 a 43, disminuyendo costos operacionales en 50.6 %

- LSTM captura patrones de degradación progresiva mediante secuencias de 30 ciclos consecutivos, información no disponible para LightGBM

6. Discusión

6.1. Validación de Hipótesis Teóricas

6.1.1. Superioridad de LSTM sobre Modelos Lineales

Los resultados experimentales confirman la hipótesis de que arquitecturas LSTM capturan mejor las dinámicas de degradación no lineal que modelos lineales clásicos:

1. **Dependencias de largo alcance:** LSTM mantiene información relevante a través de 30 ciclos, detectando tendencias graduales imperceptibles en análisis punto-a-punto.
2. **Relaciones no lineales:** La función de activación tanh y las compuertas sigmoideas permiten modelar interacciones complejas entre sensores (ej: temperatura $\times$ presión).
3. **Memoria selectiva:** Las compuertas forget/input aprenden automáticamente qué información retener (tendencias de degradación) y qué descartar (fluctuaciones operacionales normales).

6.2. Limitaciones del Estudio

6.2.1. Generalización a Otros Escenarios

El dataset FD001 representa un único escenario operacional (altitud y Mach fijos). Para deployment real se requeriría:

- Entrenamiento en datasets multimodales (FD002-004 con múltiples condiciones)
- Validación en datos reales de operación (no simulados)
- Calibración para diferentes tipos de motores turbofan

6.2.2. Interpretabilidad del Modelo

Como “caja negra”, LSTM no proporciona explicaciones directas de sus predicciones. En contextos de seguridad crítica, esto puede ser problemático para:

- Auditorías regulatorias (FAA, EASA)
- Confianza de operadores humanos
- Diagnóstico de causas raíz de fallos

Mitigación parcial: Técnicas de interpretabilidad como SHAP values, attention mechanisms, o saliency maps pueden ofrecer insights limitados.

6.3. Consideraciones de Deployment

6.3.1. Inferencia en Tiempo Real

El modelo actual procesa secuencias offline. Para monitoreo continuo se requiere:

1. **Pipeline de streaming:** Buffer circular que mantiene últimos 30 ciclos
2. **Latencia:** Inferencia LSTM es computacionalmente eficiente (< 10 ms por predicción en CPU)
3. **Actualización de modelo:** Reentrenamiento periódico con nuevos datos operacionales

6.3.2. Integración con Sistemas Existentes

- **CMMS (Computerized Maintenance Management System):** API RESTful para transmitir predicciones
- **Dashboard operacional:** Visualización en tiempo real de probabilidades de fallo
- **Sistema de alertas:** Notificaciones automáticas a ingenieros de mantenimiento